4. Regression

Topik

1. Konsep Regression
2. Linear Regression
3. Logistic Regression
4. Polynomial Regression

Tujuan

1. Mahasiswa mampu memahami konsep regression.
2. Mahasiswa mampu menerapkan teknik linear, logistic, dan polynomial regression pada suatu dataset.

Dasar Teori

Regresi adalah salah satu teknik dalam statistika yang digunakan untuk memodelkan hubungan antara satu atau lebih variabel independen (disebut juga sebagai variabel prediktor atau variabel eksplanatori) dan variabel dependen (variabel respons). Tujuannya adalah untuk memahami dan menganalisis bagaimana perubahan dalam variabel independen mempengaruhi variabel dependen.

Berikut adalah beberapa konsep penting dalam regresi:

1. **Variabel Dependen**: Variabel dependen adalah variabel yang ingin kita prediksi atau jelaskan. Ini adalah variabel yang kita harapkan akan dipengaruhi oleh variabel independen. Misalnya, jika kita sedang mempelajari hubungan antara waktu belajar dengan nilai ujian, maka nilai ujian adalah variabel dependen.

2. **Variabel Independen**: Variabel independen adalah variabel yang digunakan untuk memprediksi atau menjelaskan variabel dependen. Ini adalah variabel yang kita harapkan mempengaruhi variabel dependen. Dalam contoh sebelumnya, waktu belajar adalah variabel independen.

3. **Hubungan Linear**: Regresi linear adalah bentuk paling umum dari regresi di mana hubungan antara variabel independen dan dependen diasumsikan sebagai linear. Ini berarti bahwa perubahan dalam variabel independen berhubungan secara linier dengan perubahan dalam variabel dependen. Namun, ada juga model regresi non-linear yang memungkinkan hubungan yang lebih kompleks.

4. **Model Regresi**: Model regresi adalah representasi matematis dari hubungan antara variabel independen dan dependen. Model ini dinyatakan dalam bentuk persamaan matematis yang

memungkinkan kita untuk memprediksi nilai variabel dependen berdasarkan nilai variabel independen.

5. **Koefisien Regresi**: Koefisien regresi adalah angka-angka yang menggambarkan kekuatan dan arah hubungan antara variabel independen dan dependen dalam model regresi. Dalam regresi linear sederhana, terdapat dua koefisien: koefisien kemiringan (slope) yang menunjukkan seberapa banyak variabel dependen berubah untuk setiap satuan perubahan dalam variabel independen, dan koefisien perpotongan (intercept) yang menunjukkan nilai rata-rata dari variabel dependen ketika variabel independen sama dengan nol.

6. **Evaluasi Model**: Evaluasi model regresi penting untuk mengetahui seberapa baik model tersebut cocok dengan data. Salah satu metode evaluasi yang umum digunakan adalah MAE, RMSE, dan MAPE.

Regresi digunakan dalam berbagai bidang seperti ilmu sosial, ekonomi, ilmu alam, dan banyak lagi untuk menganalisis dan memprediksi hubungan antara variabel-variabel yang ada. Teknik regresi juga memiliki berbagai variasi dan pengembangan yang telah dikembangkan untuk menangani situasi yang lebih kompleks.

Ada beberapa jenis regresi yang umum digunakan, dan berikut ini adalah beberapa di antaranya:
1. **Regresi Linear Sederhana**: Ini adalah bentuk paling dasar dari regresi di mana hubungan antara variabel independen dan dependen diasumsikan sebagai linear. Dalam regresi linear sederhana, hanya ada satu variabel independen yang digunakan untuk memprediksi variabel dependen.

2. **Regresi Linear Berganda (Multiple Linear)**: Regresi linear berganda melibatkan lebih dari satu variabel independen untuk memprediksi variabel dependen. Model ini memungkinkan untuk mempertimbangkan pengaruh variabel-variabel independen yang lebih kompleks terhadap variabel dependen.

3. **Regresi Logistik**: Regresi logistik digunakan ketika variabel dependen adalah biner (dua kategori). Ini digunakan untuk memodelkan probabilitas kejadian suatu peristiwa berdasarkan satu atau lebih variabel independen. Misalnya, dapat digunakan dalam prediksi probabilitas keberhasilan atau kegagalan suatu peristiwa.

4. **Regresi Polinomial**: Regresi polinomial memodelkan hubungan antara variabel independen dan dependen dengan menggunakan fungsi polinomial daripada fungsi linear. Ini memungkinkan model untuk menangkap hubungan non-linear antara variabel-variabel tersebut.

Setiap jenis regresi memiliki kegunaan dan asumsi yang berbeda, dan pemilihan jenis regresi yang tepat tergantung pada sifat data dan tujuan analisis.

Terdapat tiga model regression yang akan dibahas pada materi kali ini yaitu Regresi Linear,

Regresi Logistik, dan Regresi Polinomial.

1. **Regresi Linier (Linear Regression)**

   Regresi linear adalah jenis regresi yang paling umum digunakan dan paling mudah dipahami. Ini melibatkan memodelkan hubungan linier antara satu atau lebih variabel independen (prediktor) dan variabel dependen (respons). Dalam regresi linear sederhana, hanya ada satu variabel independen yang digunakan untuk memprediksi variabel dependen, sedangkan dalam regresi linear berganda, terdapat lebih dari satu variabel independen.

   Secara matemtis, model regresi linear sederhana dapat dinyatakan sebagai berikut:

   $Y = \beta_0 + \beta_1 X + \varepsilon$

   Dimana:

   - Y adalah variabel dependen (respons).

   - X adalah variabel independen (prediktor).

   - β_0 adalah intercept (koefisien perpotongan), yaitu nilai rata-rata dari Y ketika X sama dengan nol.

   - β_1 adalah koefisien kemiringan, yang menggambarkan seberapa banyak Y berubah ketika X berubah satu satuan.

   - ε adalah kesalahan acak, yang merupakan perbedaan antara nilai yang diamati dan nilai yang diprediksi oleh model.

   Tujuan utama dari regresi linear adalah untuk memperkirakan nilai dari koefisien β_0 dan β_1 sehingga model yang dihasilkan dapat memprediksi nilai Y dengan akurat berdasarkan nilai X.

   Proses estimasi koefisien dalam regresi linear sering menggunakan metode kuadrat terkecil (Ordinary Least Squares/OLS). Metode ini mengurangi jumlah kesalahan kuadrat antara nilai yang diamati dan nilai yang diprediksi oleh model untuk menemukan estimasi yang optimal untuk koefisien.

   Pada percobaan kali ini, kita akan gunakan regresi linier pada Altair AI Studo.

   Dataset yang digunakan adalah dataset harga rumah (HousePrices).

   Perhatikan dataset **HousePrices.CSV** berikut:

house_sqft,num_of_bedrooms,num_of_bathrooms,year_built,tax_assessed_value,last_sold_price
1770,3,2,1990,195000,196358
1770,3,2,1990,195000,197715
1770,3,2,1990,195000,197816
1772,3,2,1990,200000,198011
1850,3,2.5,1990,200000,200530
1850,3,2.5,1990,200000,201805
1850,3,2.5,1990,205000,206175
1850,3,2.5,1990,205000,207027
1850,3,2.5,1990,205000,207121
1850,3,2.5,1990,205000,210519
1850,3,2.5,1990,212000,211099
1850,3,2.5,1990,212000,211274
1900,4,2.5,1990,212000,211414

Data terdiri dari 6 atribut yaitu luas rumah (house_sqft), jumlah kamar tidur (num_of_bedrooms), tahun dibangun (year_built), biaya pajak (tax_assessed_value), harga jual (last_sold_price). Dataset terdiri dari 120 sampel data.

<u>Praktikum 1:</u>

a. Di Repository, klik Import Data → My Computer. Pilih file dataset.

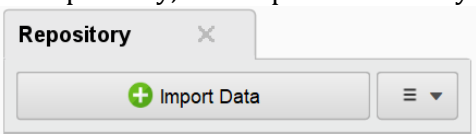

b. Pada jendela berikutnya seharusnya tertampil dataset dalam tabel yang lebih rapi. Klik Next.

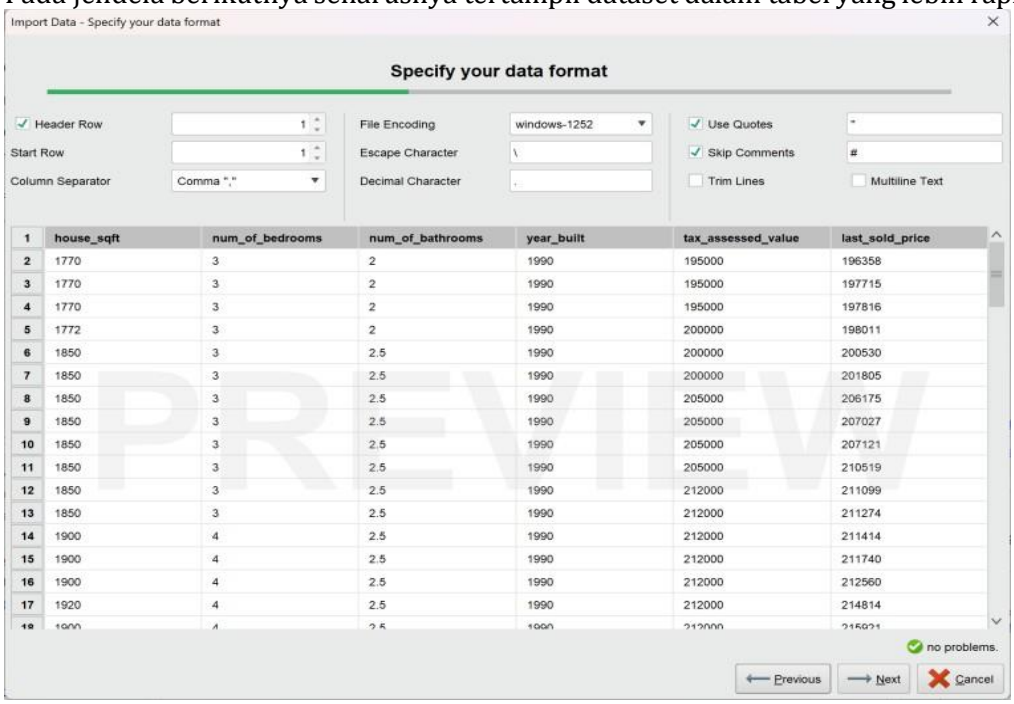

1	house_sqft	num_of_bedrooms	num_of_bathrooms	year_built	tax_assessed_value	last_sold_price
2	1770	3	2	1990	195000	196358
3	1770	3	2	1990	195000	197715
4	1770	3	2	1990	195000	197816
5	1772	3	2	1990	200000	198011
6	1850	3	2.5	1990	200000	200530
7	1850	3	2.5	1990	200000	201805
8	1850	3	2.5	1990	205000	206175
9	1850	3	2.5	1990	205000	207027
10	1850	3	2.5	1990	205000	207121
11	1850	3	2.5	1990	205000	210519
12	1850	3	2.5	1990	212000	211099
13	1850	3	2.5	1990	212000	211274
14	1900	4	2.5	1990	212000	211414
15	1900	4	2.5	1990	212000	211740
16	1900	4	2.5	1990	212000	212560
17	1920	4	2.5	1990	212000	214814

c. Tentukan prediksi apa yang akan dilakukan dengan memilih label. Karena akan memprediksi harga rumah, maka last_sold_price perlu dipilih sebagai label. Klik icon panah kecil di kolom last_sold_price → change role → label → OK. Simpan dataset di repository.

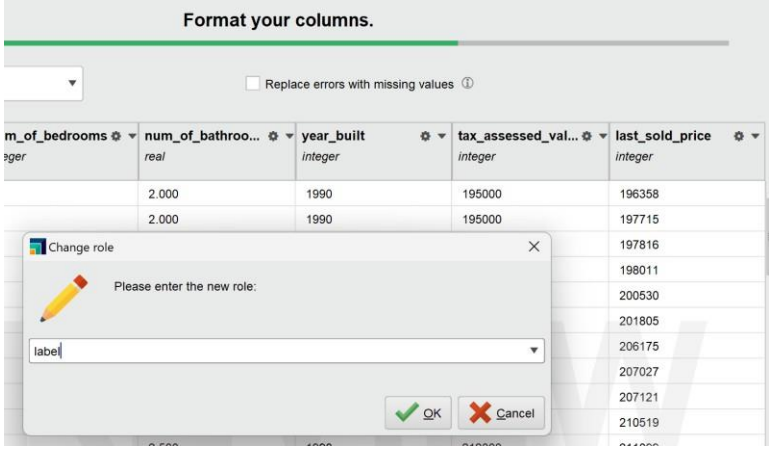

d. Jika berhasil, maka data akan ditampilkan pada menu Result seperti terlihat pada gambar berikut:

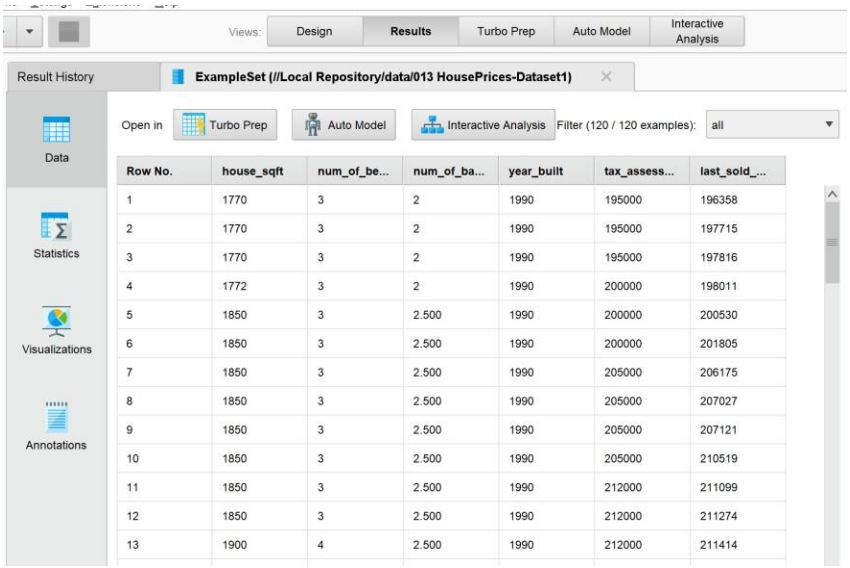

Row No.	house_sqft	num_of_be...	num_of_ba...	year_built	tax_assess...	last_sold_...
1	1770	3	2	1990	195000	196358
2	1770	3	2	1990	195000	197715
3	1770	3	2	1990	195000	197816
4	1772	3	2	1990	200000	198011
5	1850	3	2.500	1990	200000	200530
6	1850	3	2.500	1990	200000	201805
7	1850	3	2.500	1990	205000	206175
8	1850	3	2.500	1990	205000	207027
9	1850	3	2.500	1990	205000	207121
10	1850	3	2.500	1990	205000	210519
11	1850	3	2.500	1990	212000	211099
12	1850	3	2.500	1990	212000	211274
13	1900	4	2.500	1990	212000	211414

e. Langkah berikutnya yang dilakukan adalah dengan drag dataset tersebut dari jendela Repository dan drop pada jendela Design, sehingga muncul blok Retrieve… seperti terlihat pada gambar berikut:

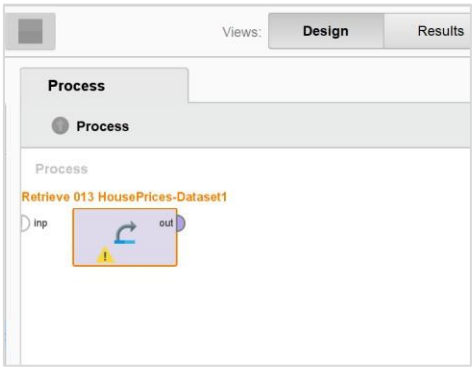

f. Perhatikan bahwa Regresi merupakan Machine Learning yang membuat model prediksi dengan menggunakan data pembelajaran (training data). Dataset yang tersedia kemudian perlu dibagi menjadi dua, data pembelajaran dan data pengujian (testing data). Data pembelajaran digunakan untuk membentuk model dengan akurasi sebaik-baiknya, sedangkan data pengujian digunakan sebagai data penguji model yang dibentuk dari data pembelajaran. Sampel data untuk pengujian tidak boleh pernah digunakan sebagai sampel data pembelajaran, sehingga langkah berikutnya yang perlu dilakukan adalah melakukan pemisahan data dari dataset (Split Data). Data akan dipisahkan menjadi data pembelajaran dan data pengujian. Secara umum biasanya dibagi dari dataset untuk pembelajaran sebanyak 2/3 sampel data dan sisanya untuk data pengujian.

Gunakan operator Split Data untuk memisahkan dataset. Di Parameters, klik Edit Enumeration. Klik Add Entry, set 0.667 untuk training dan 0.333 untuk testing.

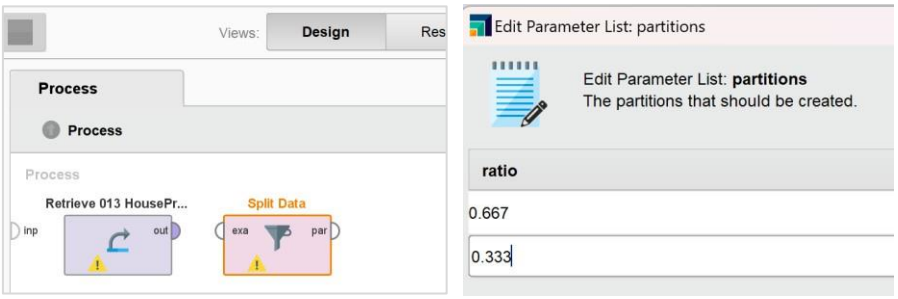

g. Hubungkan tiap relasinya seperti gambar berikut, run process, dan lihat hasilnya:

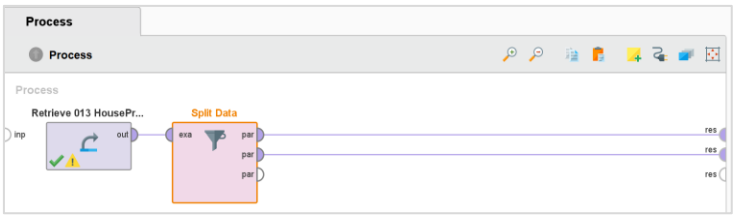

h. Pada Data Training Terdapat 80 sampel data, dan Data Testing terdapat 40 sampel data

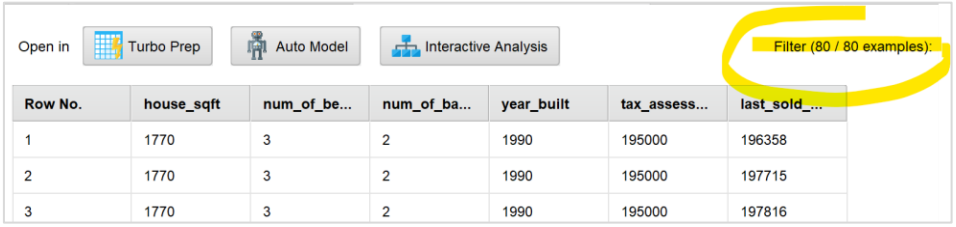

Row No.	house_sqft	num_of_be...	num_of_ba...	year_built	tax_assess...	last_sold_...
1	1770	3	2	1990	195000	196358
2	1770	3	2	1990	195000	197715
3	1770	3	2	1990	195000	197816

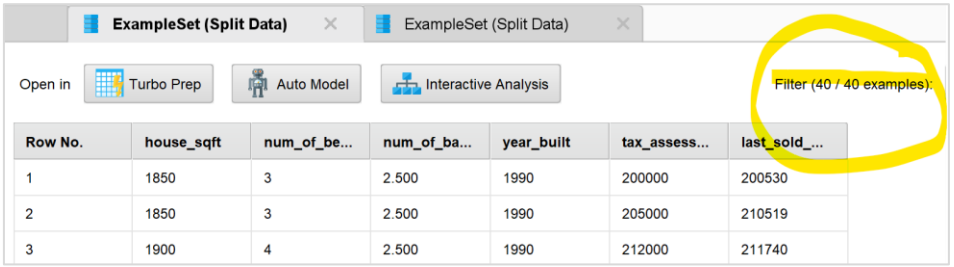

Row No.	house_sqft	num_of_be...	num_of_ba...	year_built	tax_assess...	last_sold_...
1	1850	3	2.500	1990	200000	200530
2	1850	3	2.500	1990	205000	210519
3	1900	4	2.500	1990	212000	211740

i. Karena akan menggunakan Linear Regression, maka pilih operator Linear Regression dan sambungkan pada data training Split Data. Model yang dihasilkan akan diuji coba menggunakan data testing dari test data, sehingga operator Apply model digunakan untuk operasi ini. Perhatikan gambar berikut untuk relasinya dan perhatikan juga hasilnya

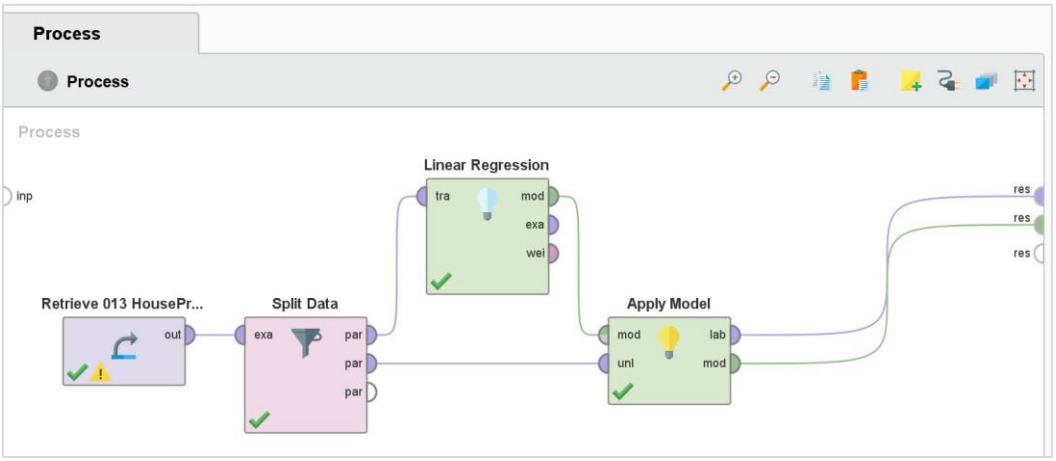

Row No.	last_sold_...	prediction(...	house_sqft	num
1	200530	201229.851	1850	3
2	210519	206200.805	1850	3
3	211740	213260.422	1900	4
4	215921	213260.422	1900	4
5	216623	216283.108	1920	4

ry | LinearRegression (Linear Regression) | ExampleSet (Apply Model)

Attribute	Coefficient	Std. Error	Std. Coefficient	Tolerance	t-Stat	p-Value	Code
house_sqft	2.006	0.790	0.018	0.554	2.538	0.013	**
num_of_bathro...	-1680.723	703.366	-0.011	0.736	-2.390	0.019	**
year_built	90.455	78.657	0.011	0.176	1.150	0.254	
tax_assessed_...	0.994	0.012	0.984	0.054	86.206	0	****
(Intercept)	-177122.074	154625.372	?	?	-1.145	0.256	

j. Blok Performance (Regression) dapat ditambahkan untuk melihat sejauh mana error yang terjadi pada model yang dibentuk. Run process dan lihat hasil RMSE nya.

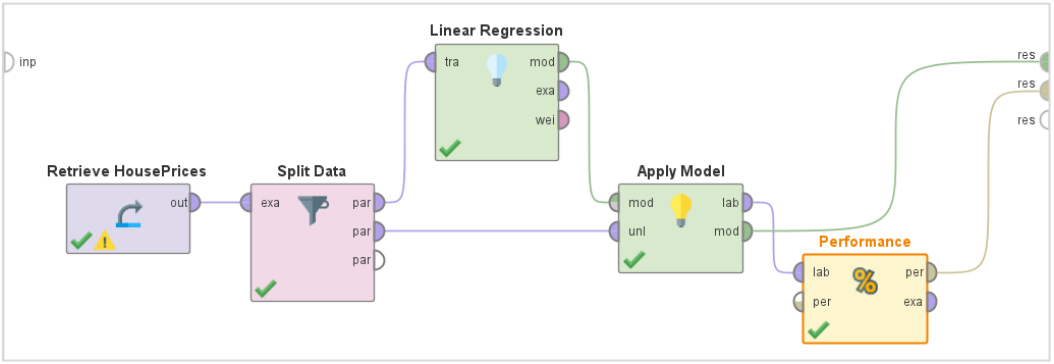

root_mean_squared_error

```
root_mean_squared_error: 2085.444 +/- 0.000
```

2. **Regresi Logistik (Logistic Regression)**

Regresi logistik adalah teknik statistik yang digunakan untuk memodelkan hubungan antara satu atau lebih variabel independen (prediktor) dengan variabel dependen yang bersifat biner (dua kategori). Ini adalah alat yang sangat berguna dalam analisis klasifikasi dan prediksi di mana variabel dependen adalah variabel biner, seperti sukses/gagal, ya/tidak, atau 1/0.

Secara umum, regresi logistik menghasilkan probabilitas bahwa suatu kejadian terjadi berdasarkan nilai-nilai variabel independen. Dalam konteks klasifikasi biner, model regresi logistik mencoba memprediksi probabilitas bahwa suatu observasi akan termasuk dalam kategori yang ditentukan (misalnya, "positif" atau "negatif").

Model regresi logistik menghasilkan output dalam bentuk odds (rasio probabilitas sukses terhadap probabilitas gagal) yang diperlakukan sebagai fungsi linier dari variabel independen. Namun, karena nilai odds dapat bervariasi dari nol hingga tak terbatas, regresi

logistik menggunakan fungsi logistik (sigmoid) untuk mengubah output menjadi probabilitas yang berada dalam rentang 0 hingga 1.

Secara matematis, regresi logistik dapat dijelaskan sebagai berikut:

$$P(Y = 1|X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \cdots + \beta_n X_n)}}$$

Di mana:

- $P(Y = 1|X)$ adalah probabilitas bahwa variabel dependen Y adalah 1 (sukses) berdasarkan nilai-nilai variabel independen X
- $\beta_0, \beta_1, \ldots, \beta_n$ adalah koefisien regresi yang harus diestimasi.
- $X_1, X_2, \ldots X_n$ adalah nilai-nilai variabel independen.
- e adalah basis logaritma natural (euler's number).

Koefisien regresi $\beta_0, \beta_1, \ldots, \beta_n$ diestimasi menggunakan teknik optimasi seperti metode maksimum likelihood.

Regresi logistik sangat berguna dalam berbagai aplikasi seperti analisis risiko kredit, pemodelan risiko kesehatan, prediksi keberhasilan pemasaran, dan lain-lain. Model ini adalah alat yang penting dalam analisis data klasifikasi di mana variabel dependen adalah biner.

<u>Praktikum 2:</u>

a. Lakukan percobaan yang sama pada dataset Voice. Data ini berisi sampel suara dari pria dan wanita. Logistic Regression akan digunakan untuk memprediksi suara pria atau wanitakah pada data testing yang ditentukan. Tambahkan performance (binomial) untuk melihat performance dari model yang dibuat

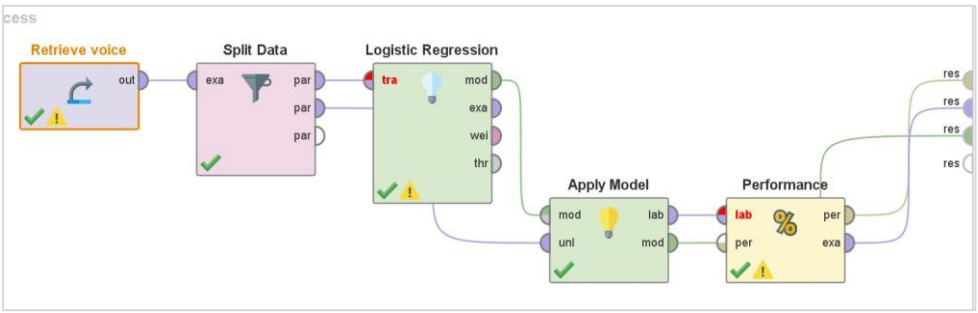

b. Performa model ditunjukkan melalui metrik accuracy 97.25%

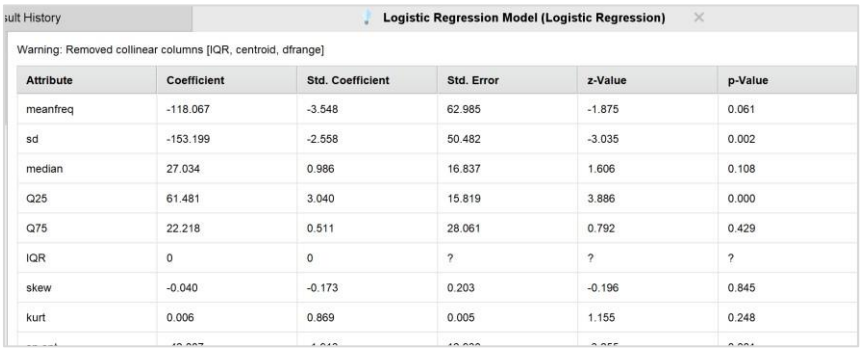

Logistic Regression Model (Logistic Regression)

Warning: Removed collinear columns [IQR, centroid, dfrange]

Attribute	Coefficient	Std. Coefficient	Std. Error	z-Value	p-Value
meanfreq	-118.067	-3.548	62.985	-1.875	0.061
sd	-153.199	-2.558	50.482	-3.035	0.002
median	27.034	0.986	16.837	1.606	0.108
Q25	61.481	3.040	15.819	3.886	0.000
Q75	22.218	0.511	28.061	0.792	0.429
IQR	0	0	?	?	?
skew	-0.040	-0.173	0.203	-0.196	0.845
kurt	0.006	0.869	0.005	1.155	0.248

ExampleSet (Apply Model) | PerformanceVector (Performance)

Result History | Logistic Regression Model (Logistic Regression)

Open in | Turbo Prep | Auto Model | Interactive Analysis | Filter (1,054 / 1,054 examples): all

Row No.	label	prediction(...	confidence...	confidence...	meanfreq	sd	median	Q25
1	male	male	1.000	0.000	0.151	0.072	0.158	0.097
2	male	male	1.000	0.000	0.161	0.077	0.144	0.111
3	male	male	1.000	0.000	0.137	0.081	0.124	0.083
4	male	male	0.771	0.229	0.181	0.060	0.191	0.129
5	male	male	0.993	0.007	0.191	0.066	0.208	0.132

accuracy: 97.25%

	true male	true female	class precision
pred. male	512	14	97.34%
pred. female	15	513	97.16%
class recall	97.15%	97.34%	

3. **Regresi Polinomial (Polynomial Regression)**

Regresi polinomial adalah jenis regresi yang memodelkan hubungan antara variabel independen dan dependen menggunakan fungsi polinomial, bukan fungsi linear seperti dalam regresi linear. Ini memungkinkan kita untuk menangkap hubungan yang lebih kompleks antara variabel-variabel tersebut.

Dalam regresi polinomial, variabel independen tidak hanya dipertimbangkan dalam bentuk linear, tetapi juga dalam bentuk pangkat-pangkat tertentu (misalnya, kuadrat, kubik, dll.). Oleh karena itu, model regresi polinomial memiliki bentuk umum sebagai berikut:

$$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \beta_3 X^3 + \cdots + \beta_n X^n + \varepsilon$$

Dimana:

- Y adalah variabel dependen.
- X adalah variabel independen.
- $\beta_0,\ \beta_1,\ \beta_2,\ \beta_3, \ldots, \beta_n$ adalah koefisien regresi yang harus diestimasi.
- ε adalah kesalahan acak.

Jumlah pangkat tertinggi dari X dalam model polinomial ditentukan oleh derajat polinomial yang dipilih. Sebagai contoh, regresi polinomial derajat dua akan menghasilkan model dengan satu variabel independen X dan satu pangkat kedua dari $X(X^2)$, sedangkan regresi polinomial derajat tiga akan menambahkan pangkat ketiga (X^3), dan seterusnya.

Proses estimasi koefisien dalam regresi polinomial melibatkan teknik yang mirip dengan regresi linear, di mana kita mencari koefisien yang meminimalkan jumlah kuadrat kesalahan antara nilai yang diamati dan nilai yang diprediksi oleh model.

Regresi polinomial sangat berguna ketika hubungan antara variabel independen dan dependen tidak dapat dijelaskan dengan baik oleh model linear. Ini memungkinkan kita untuk menangkap pola-pola yang lebih kompleks dalam data. Namun, perlu diingat bahwa regresi polinomial dengan derajat yang tinggi cenderung lebih rentan terhadap overfitting, sehingga pemilihan derajat yang tepat penting untuk menghindari masalah tersebut.

<u>Praktikum 3</u>:

a. Pada dua percobaan sebelumnya anda menggunakan dataset yang telah ada, pada percobaan kali ini akan dibuat data baru berbentuk polinomial. Blok proses Generate Data dapat digunakan untuk membuat dataset khususnya polinomial (target function). Jumlah example dan atribut bisa kita set sesuai keinginan, pada percobaan ini dibuat 300 example dan 3 atribut. Perhatikan hasil generate datanya.

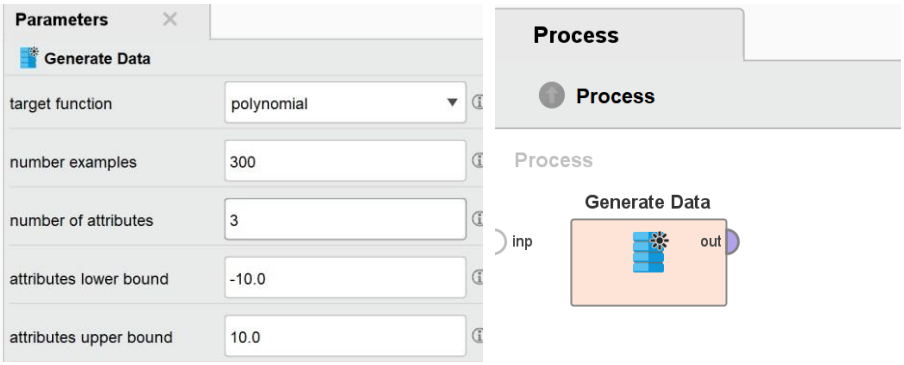

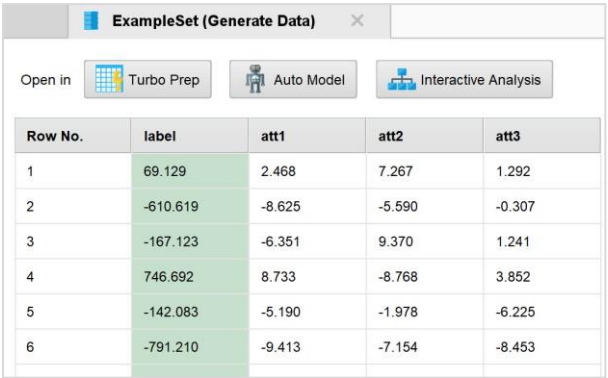

Row No.	label	att1	att2	att3
1	69.129	2.468	7.267	1.292
2	-610.619	-8.625	-5.590	-0.307
3	-167.123	-6.351	9.370	1.241
4	746.692	8.733	-8.768	3.852
5	-142.083	-5.190	-1.978	-6.225
6	-791.210	-9.413	-7.154	-8.453

b. Tampilkan grafik menggunakan line dan muncul grafik polinomial pada labelnya seperti gambar berikut:

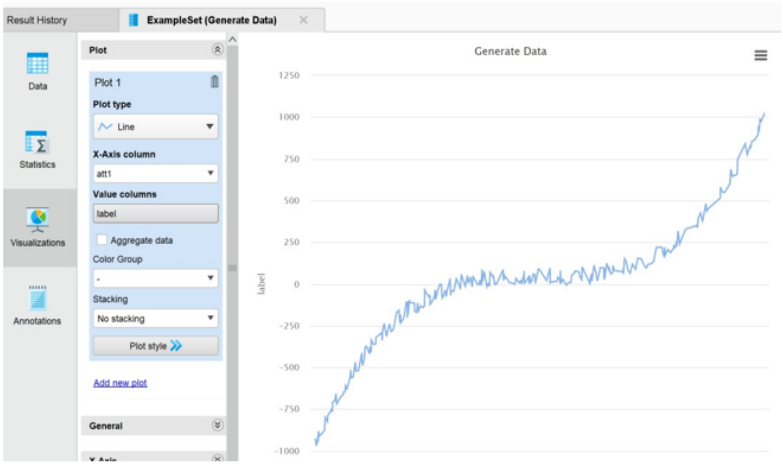

c. Lakukan prediksi menggunakan Polynomial Regression dan perhatikan hasilnya:

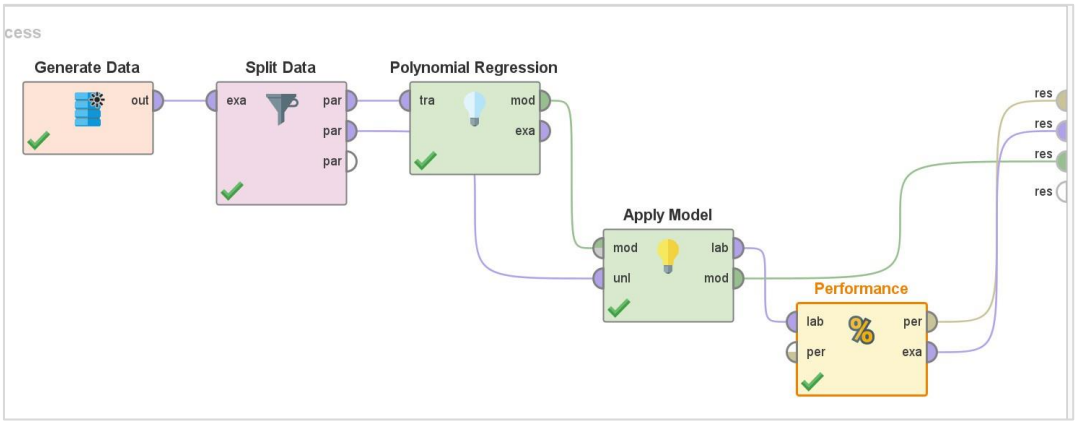

ExampleSet (Apply Model) | PerformanceVe
sult History | PolynomialRegression (Polynomial Re

Open in Turbo Prep | Auto Model | Interactive Analysis

Row No.	label	prediction(...	att1	att2	att3
1	746.692	615.662	8.733	-8.768	3.852
2	-142.083	-332.173	-5.190	-1.978	-6.225
3	-78.931	-248.924	-4.696	-4.395	5.304
4	-7.319	-126.967	-2.017	0.911	0.057
5	-36.461	-183.929	-5.118	9.485	7.661
6	57.018	50.693	-0.258	7.311	3.584
7	580.024	558.097	7.980	8.314	2.705
8	-204.472	-336.083	-6.042	-3.029	6.953
9	15.481	-127.027	-2.665	-5.893	-0.325

root_mean_squared_error

```
root_mean_squared_error: 135.437 +/- 0.000
```

sult History

PolynomialRegression

```
  59.689 * att1 ^ 1.000
+ 1.174 * att2 ^ 2.000
+ 3.097 * att3 ^ 1.000
- 7.725
```

d. Gambar berikut merupakan grafik hasil prediksi dan data asli dan bandingkan hasilnya. Catat hasil percobaan dan buat kesimpulan

Praktikum 4 – Linear Regression dengan Python

Pada praktikum ini Anda akan mencoba melakukan linear regression pada dataset Advertising Budget untuk melakukan prediksi jumlah penjualan produk berdasarkan advertising budget menggunakan python di Google Colab.

1. Import library yang diperlukan

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn.linear_model import LinearRegression
```

2. Run code berikut lalu upload Advertising Budget dataset.

```
from google.colab import files
uploaded = files.upload()
```

3. Load dataset

```
data = pd.read_csv("Advertising.csv")
data.head()
```

	Advertising_Budget_USD	Product_Sales_Units
0	500	52
1	700	65
2	800	70
3	900	75
4	1100	88

4. Lakukan eksplorasi data

```
data.info()
```

```
data.describe()
```

5. Tentukan Advertising Budget sebagai independent variable (x) dan Product Sales Unit sebagai dependent variable (y)

```
X = data[['Advertising_Budget_USD']]
y = data['Product_Sales_Units']
```

6. Buat scatter plot untuk memvisualisasikan data.

```
plt.scatter(X, y)
plt.xlabel("Advertising Budget (USD)")
plt.ylabel("Product Sales (Units)")
plt.title("Advertising Budget vs Product Sales")
plt.show()
```

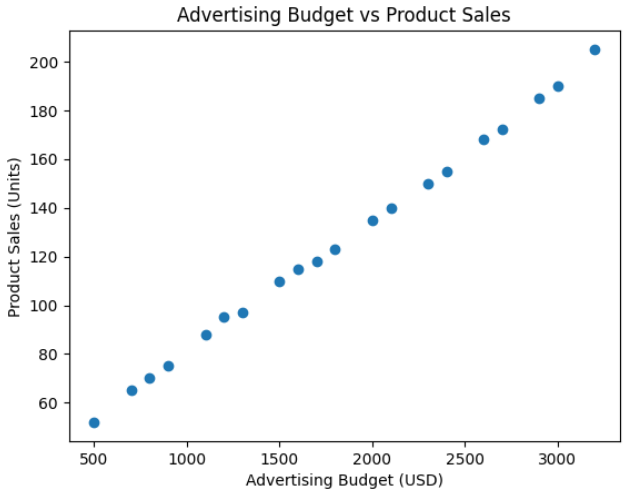

7. Buat regresi linear dan cetak nilai slope / koefisien regresi dan intercept

```
model = LinearRegression()
model.fit(X, y)
```

```
print("Intercept:", model.intercept_)
print("Slope:", model.coef_[0])
```

```
Intercept: 26.347181358126406
Slope: 0.05457455572555019
```

8. Visualisasi hasil regresi

```
y_pred = model.predict(X)

plt.scatter(X, y)
plt.plot(X, y_pred)
plt.xlabel("Advertising Budget")
plt.ylabel("Product Sales")
plt.title("Linear Regression Result")
plt.show()
```

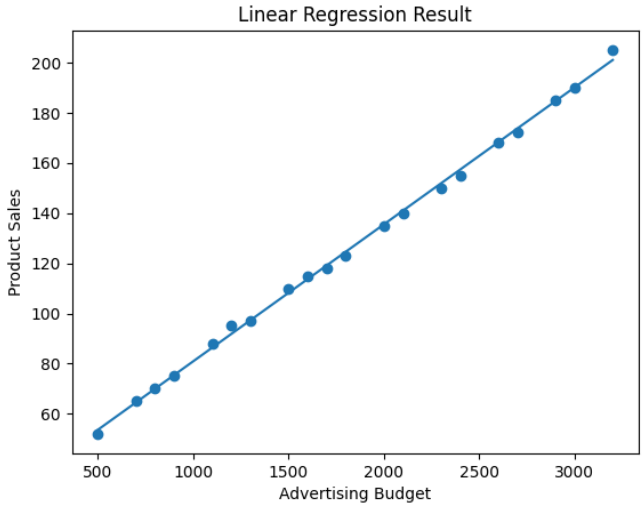

9. Coba lakukan prediksi jumlah penjualan jika advertising budget 2500

```
prediksi = model.predict([[2500]])
print("Prediksi penjualan:", prediksi[0])
```

```
Prediksi penjualan: 162.78357067200187
```

Praktikum 5 – Logistic Regression dengan Python

Pada dataset yang sama yaitu Voice.csv, Anda akan mencoba melakukan prediksi data suara male/female dengan logistic regression menggunakan python.

1. Import library yang dibutuhkan

```
import pandas as pd
import numpy as np

from sklearn.model_selection import train_test_split
from sklearn.preprocessing import LabelEncoder
from sklearn.preprocessing import StandardScaler

from sklearn.linear_model import LogisticRegression
from sklearn.metrics import accuracy_score

import seaborn as sns
import matplotlib.pyplot as plt
```

2. Run code berikut kemudian upload voice dataset

```
from google.colab import files
uploaded = files.upload()
```

3. Load dataset

```
df = pd.read_csv('voice.csv')
df.head()
```

4. Lakukan eksplorasi dataset

```
df.info()
df.describe()
```

5. Cek jumlah data untuk setiap kelas

```
df['label'].value_counts()
```

	count
label	
male	1584
female	1584

dtype: int64

6. Pisahkan fitur dan label

```
X = df.drop('label', axis=1)
y = df['label']
```

7. Karena model membutuhkan data numerik, lakukan encoding. Mapping label biasanya male: 1 dan female: 0

```
le = LabelEncoder()
y = le.fit_transform(y)

y[:10]
```

```
array([1, 1, 1, 1, 1, 1, 1, 1, 1, 1])
```

8. Normalisasi data agar semua fitur berada pada skala yang sama

```
scaler = StandardScaler()
X = scaler.fit_transform(X)
```

9. Bagi dataset menjadi 80% training dan 20% testing

```
X_train, X_test, y_train, y_test = train_test_split(
    X, y,
    test_size=0.2,
    random_state=42
)
```

10. Cek ukuran data hasil splitting

```
print("Training data:", X_train.shape)
print("Testing data:", X_test.shape)
```

```
Training data: (2534, 20)
Testing data: (634, 20)
```

11. Bangun model logistic regression

```
model = LogisticRegression()

model.fit(X_train, y_train)
```

12. Lakukan prediksi, cetak beberapa hasil

```
y_pred = model.predict(X_test)
```

13. Lakukan evaluasi model dengan menghitung nilai akurasi

```
accuracy = accuracy_score(y_test, y_pred)
print("Accuracy:", accuracy)
```

```
Accuracy: 0.9810725552050473
```

Praktikum 6 – Polynomial Regression dengan Python

Pada praktikum ini Anda akan menganalisis hubungan antara kecepatan kendaraan dan konsumsi bahan bakar menggunakan Polynomial Regression.

1. Import library yang diperlukan

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

from sklearn.preprocessing import PolynomialFeatures
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error
from sklearn.model_selection import train_test_split
```

2. Run code berikut dan upload dataset fuel_efficiency_speed.csv

```
from google.colab import files
uploaded = files.upload()
```

3. Load dataset

```
data = pd.read_csv("fuel_efficiency_speed.csv")
data.head()
```

4. Lakukan eksplorasi dataset

```
df.info()
df.describe()
```

5. Buat visualisasi dengan scatter plot. Perhatikan bahwa titik data membentuk kurva U, bukan garis lurus

```
plt.scatter(data['speed_kmh'], data['fuel_consumption'])
plt.xlabel("Kecepatan (km/h)")
plt.ylabel("Konsumsi BBM (L/100km)")
plt.title("Hubungan Kecepatan dan Konsumsi BBM")
plt.show()
```

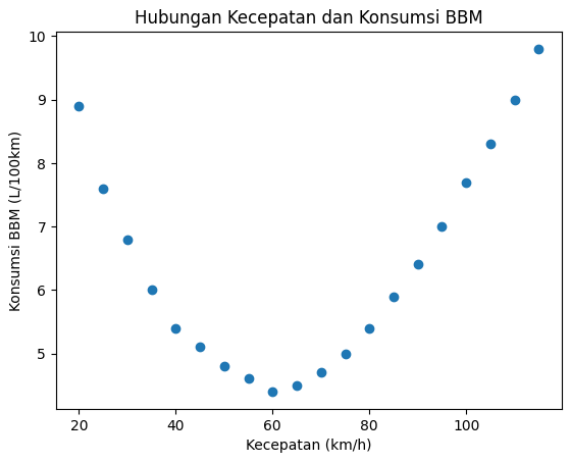

6. Pisahkan variabel independen (X) dan dependen (y)

```
X = data[['speed_kmh']]
y = data['fuel_consumption']
```

7. Bagi data training dan data testing (80% data training dan 20% data testing)

```
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42
)
```

8. Lakukan percobaan dengan polynomial degree 2

```
poly = PolynomialFeatures(degree=2)

X_train_poly = poly.fit_transform(X_train)
X_test_poly = poly.transform(X_test)
```

9. Bangun model regresi

```
model = LinearRegression()
model.fit(X_train_poly, y_train)
```

10. Lakukan prediksi pada data training dan testing

```
y_train_pred = model.predict(X_train_poly)
y_test_pred = model.predict(X_test_poly)
```

11. Evaluasi model dengan menghitung Root Mean Square Error (RMSE)

```
rmse_train = np.sqrt(mean_squared_error(y_train, y_train_pred))
rmse_test = np.sqrt(mean_squared_error(y_test, y_test_pred))

print("RMSE Training:", rmse_train)
print("RMSE Testing:", rmse_test)
```

```
RMSE Training: 0.16936915917924067
RMSE Testing: 0.5614516586136128
```

12. Visualisasi polynomial regression

```
plt.scatter(X, y, color='blue', label='Data Asli')

X_sorted = np.sort(X.values, axis=0)
X_sorted_poly = poly.transform(X_sorted)

y_sorted_pred = model.predict(X_sorted_poly)

plt.plot(X_sorted, y_sorted_pred, color='red', label='Polynomial Regression')

plt.xlabel("Kecepatan Kendaraan (km/jam)")
plt.ylabel("Konsumsi BBM (Liter/100km)")
plt.title("Polynomial Regression")

plt.legend()

plt.show()
```

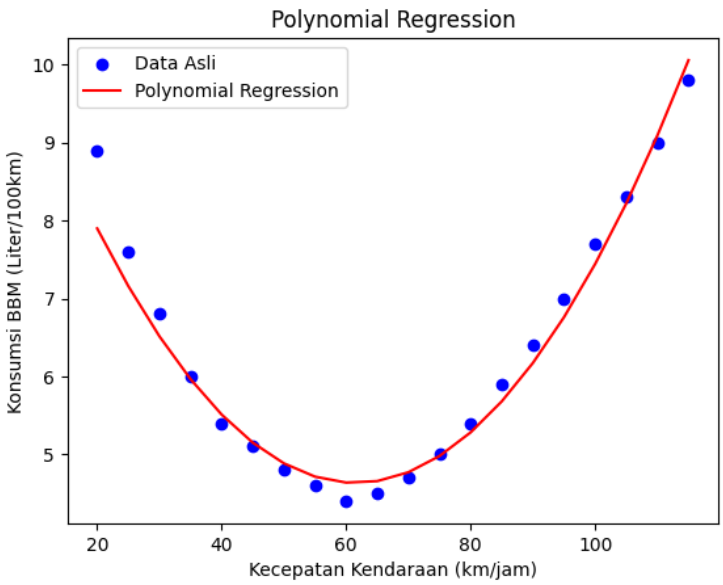

13. Coba lakukan prediksi konsumsi BBM pada kecepatan 120 km/jam.

```
new_speed = np.array([[120]])

new_speed_poly = poly.transform(new_speed)

prediction = model.predict(new_speed_poly)

print("Prediksi konsumsi BBM:", prediction[0])
```

Tugas

1. Pilih salah satu dari dataset berikut, tuliskan deskripsi dataset, lakukan Linear Regression dan tuliskan hasil percobaan anda, termasuk fungsi regresi yang dibuat dan performa model.
   a. https://archive.ics.uci.edu/dataset/186/wine+quality
   b. https://www.kaggle.com/datasets/nehalbirla/vehicle-dataset-from-cardekho
   c. https://www.kaggle.com/datasets/kumarajarshi/life-expectancy-who
   d. https://www.kaggle.com/datasets/quantbruce/real-estate-price-prediction
   e. https://www.kaggle.com/datasets/mirichoi0218/insurance
   f. https://www.kaggle.com/datasets/dgawlik/nyse
   g. https://www.kaggle.com/datasets/spittman1248/cdc-data-nutrition-physical-activity-obesity

2. Pilih salah satu dari dataset berikut, tuliskan deskripsi dataset, lakukan Logistic Regression dan tentukan performa model.
   a. https://www.kaggle.com/datasets/nimapourmoradi/abalones-age
   b. https://www.kaggle.com/datasets/nimapourmoradi/adult-incometrain-test-dataset
   c. https://www.kaggle.com/datasets/dileep070/heart-disease-prediction-using-logistic-regression
   d. https://www.kaggle.com/datasets/vikasukani/loan-eligible-dataset
   e. https://www.kaggle.com/datasets/nareshbhat/health-care-data-set-on-heart-attack-possibility
   f. https://www.kaggle.com/datasets/anyasorc/valentine-dataset
   g. https://www.kaggle.com/datasets/kandij/diabetes-dataset

3. Gunakan data harga labu berikut untuk membuat prediksi menggunakan Polynomial regression dan tentukan performa model

   https://www.kaggle.com/code/residentmario/pumpkin-price-polynomial-regression/input?select=new-york_9-24-2016_9-30-2017.csv

--- SELAMAT BELAJAR ---