Data Mining

Jobsheet 1

Muhammad Annora Ega Prasetyo

244107060069

SIB 2C

_

Soal I

2. Lakukan perubahan khusus untuk atribut Pendapatan yang diganti dengan nilai minimum. (Hint: pada Parameters, klik Show Advanced Parameters → Edit List field columns → Set untuk setiap kolom dengan missing value dengan Add Entry → Apply → Run). Screenshot hasilnya.

Jawaban:

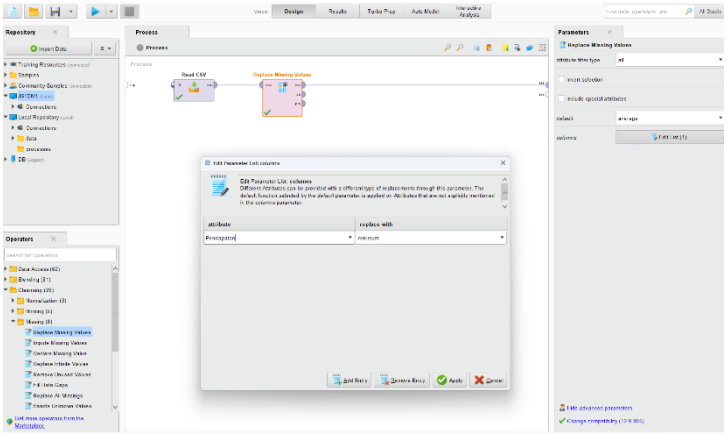

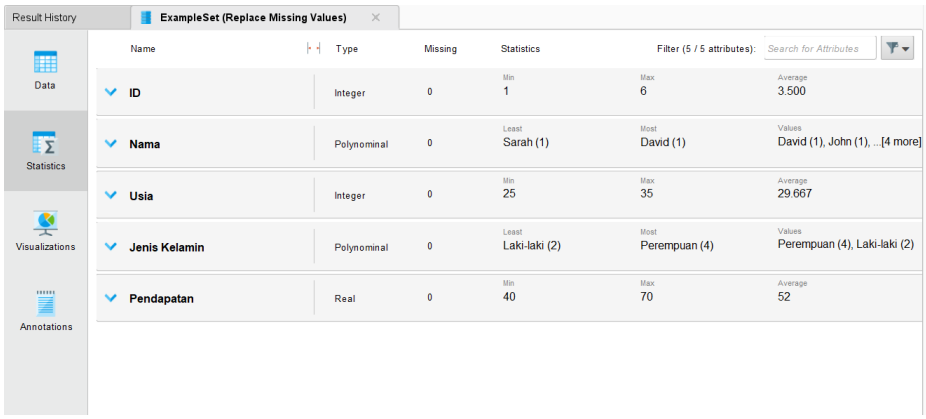

Tugas

Pilih suatu dataset, Anda bisa mencari di Kaggle/sumber lain atau gunakan salah satu sample dataset yang disediakan Altair AI Studio.

1. Lakukan outlier detection (metode bebas, pilih satu saja). Screenshot process final yang disusun (bagian Design dan Result, tidak perlu per langkah). Jelaskan setiap operator yang digunakan.

Jawaban:

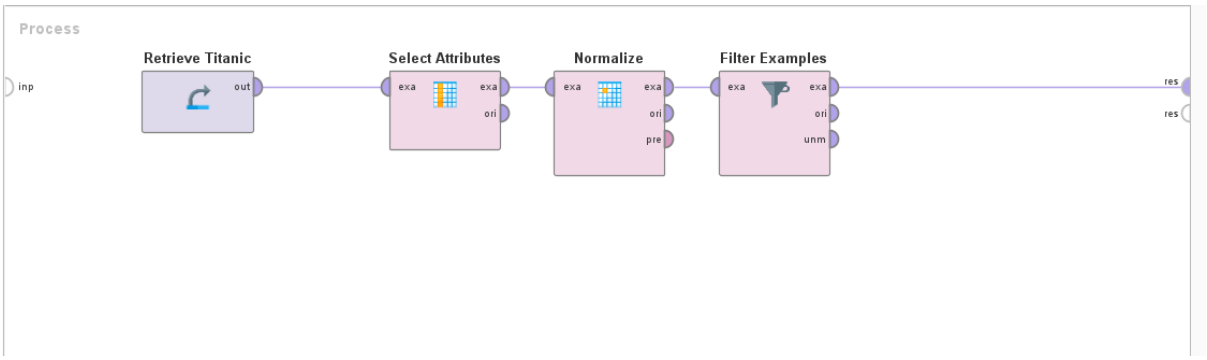

Open in Turbo Prep Auto Model Interactive Analysis Filter (1,006 / 1,006 examples): all

Row No.	Age	Passenger ...
1	-2.010	2.285
2	-1.934	2.285
3	0.008	2.285
4	-0.339	2.285
5	1.257	-0.130
6	2.298	0.863
7	0.633	-0.643
8	1.604	0.351
9	2.853	0.313
10	-0.408	0.696
11	-0.269	0.880
12	0.147	0.831
13	0.425	0.810
14	0.494	0.372
15	1.188	0.372
16	-0.269	-0.064
17	-0.339	-0.141
18	-0.339	1.116
19	-0.755	1.116
20	0.355	1.977
21	-0.131	-0.130
22	1.049	0.043
23	0.702	-0.044
24	0.008	2.542
25	1.951	-0.130
26	0.841	-0.130

Penjelasan:

- **Retreive Titanic:** Operator ini digunakan untuk mengambil dataset Titanic dari repository RapidMiner sebagai data awal yang akan diproses.

- **Select Attributes:** Operator ini digunakan untuk memilih atribut numerik yang relevan, seperti Age dan Fare, karena metode Z-score hanya dapat diterapkan pada data numerik.

- **Normalize:** Operator ini digunakan untuk mengubah nilai atribut menjadi bentuk Z-score, sehingga dapat diketahui seberapa jauh suatu data dari rata-rata.

- **Filter Examples:** Operator ini digunakan untuk menyaring data dengan cara menghapus nilai yang berada di luar rentang -3 hingga 3, yang dianggap sebagai outlier.

- **Result:** Operator ini menampilkan hasil akhir data setelah proses deteksi dan penghapusan outlier dilakukan.

2. Lakukan Handling Missing Value, Data Reduction, dan/atau Feature Construction pada data tersebut. Screenshot process final yang disusun (bagian Design dan Result, tidak perlu per langkah). Jelaskan setiap operator yang digunakan.

Jawaban:

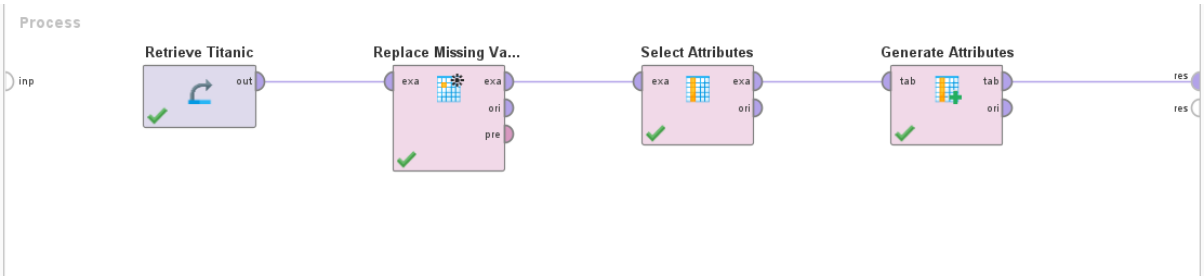

Open in Turbo Prep Auto Model Interactive Analysis Filter (1,309 / 1,309 examples): all

Row No.	Passenger ...	Sex	Age	Passenger ...	Survived	Age_group
1	First	Female	29	211.338	Yes	Adult
2	First	Male	0.917	151.550	Yes	Child
3	First	Female	2	151.550	No	Child
4	First	Male	30	151.550	No	Adult
5	First	Female	25	151.550	No	Adult
6	First	Male	48	26.550	Yes	Adult
7	First	Female	63	77.958	Yes	Old
8	First	Male	39	0	No	Adult
9	First	Female	53	51.479	Yes	Adult
10	First	Male	71	49.504	No	Old
11	First	Male	47	227.525	No	Adult
12	First	Female	18	227.525	Yes	Adult
13	First	Female	24	69.300	Yes	Adult
14	First	Female	26	78.850	Yes	Adult
15	First	Male	80	30	Yes	Old
16	First	Male	29.881	25.925	No	Adult
17	First	Male	24	247.521	No	Adult
18	First	Female	50	247.521	Yes	Adult
19	First	Female	32	76.292	Yes	Adult
20	First	Male	36	75.242	No	Adult
21	First	Male	37	52.554	Yes	Adult
22	First	Female	47	52.554	Yes	Adult
23	First	Male	26	30	Yes	Adult
24	First	Female	42	227.525	Yes	Adult
25	First	Female	29	221.779	Yes	Adult
26	First	Male	25	26	No	Adult

ExampleSet (1,309 examples,0 special attributes,6 regular attributes)

Penjelasan:

1. Retrieve Titanic

Operator ini digunakan untuk mengambil dataset Titanic dari repository RapidMiner sebagai data awal yang akan diproses.

2. Replace Missing Values

Operator ini digunakan untuk menangani nilai yang hilang (missing value) pada dataset. Biasanya nilai kosong pada atribut seperti **Age** akan diisi dengan nilai rata-rata (average), sehingga data menjadi lengkap dan dapat diproses lebih lanjut.

3. Select Attributes

Operator ini digunakan untuk melakukan **data reduction**, yaitu memilih atribut yang relevan saja dan menghapus atribut yang tidak diperlukan.
Tujuannya agar proses analisis menjadi lebih efisien dan fokus.

4. Generate Attributes

Operator ini digunakan untuk membuat atribut baru (feature construction).
Pada proses ini dibuat atribut baru bernama **Age_group**, yang mengelompokkan umur menjadi kategori seperti:

- Child
- Adult
- Old

Tujuannya agar data lebih mudah dianalisis dan dipahami.

5. Result

Operator ini menampilkan hasil akhir dari seluruh proses preprocessing yang telah dilakukan.